AI 评测体系方法论 V1.2

版本：V1.2

日期：2026 年 10 月 14 日

作者：王晓芳

适用范围：RAG 系统、Agent 系统、Prompt 安全测试

目录

0. 版本与修订记录 4

1. 总则 4

1.1 目的 4

1.2 适用范围 4

1.3 评测原则 4

1.4 术语定义 5

2. 评测集设计 5

2.1 题型分类 5

2.2 文档来源与切片策略 6

2.3 golden 构造规范 6

2.4 难度分级 6

3. 评测执行 7

3.1 Harness 架构 7

3.2 模型接入规范 7

王晓芳 | AI测试评测 | 2026-10

3.3 执行流程 7
3.4 日志与输出 8
4. 评分体系 8
4.1 LLM-as-Judge 设计 8
4.2 评分细则编写规范 8
4.3 Judge 校准 9
4.4 Judge 工程可靠性 9
4.4.1 位置偏差检测 9
4.5 人工复核机制 10
5. 结果分析 10
5.1 整体指标 10
5.2 分题型指标 10
5.3 典型 case 分析 11
5.4 模型对比方法 11
6. 统计可靠性 11
6.1 为什么需要重复采样 11
6.2 实验设计 11
6.3 统计指标定义 12
6.4 稳定性判定 12
6.5 案例：Q15a/Q15b 12
6.6 建议 12

王晓东丨AI测试评测丨2026-10

7. 评测指标 13
7.1 指标分类 13
7.2 分类指标 13
7.3 生成指标 13
7.4 评分指标 13
7.5 指标计算状态 14
8. 质量门禁 14
8.1 上线前门禁标准 14
8.2 门禁执行流程 15
8.3 不通过的处理 15
9. 持续迭代 15
9.1 评测集版本管理 15
9.2 评分标准修订流程 15
9.3 模型迭代回归 16
10. 附录 16
10.1 模板：golden 编写模板 16
10.2 模板：评分细则模板 16
10.3 模板：评测报告模板 16
10.4 案例：18 题 RAG 评测 17
10.5 资产清单 17

王晓芳 | AI测试评测 | 2026-10

0. 版本与修订记录

版本	日期	修订内容	作者
V1.0	2026-10-14	初版，整合 RAG 评测、Agent 评测、安全测试、质量门禁	王晓芳
V1.1	2026-10-14	新增第 6 章“统计可靠性”、第 7 章“评测指标”；原第 6/7/8 章顺延为第 8/9/10 章	王晓芳
V1.1	2026-10-15	4.4 节新增"位置偏差检测"结论	王晓芳
V1.2	2026-10-17	统一将评测集口径更新为 19 题，修正 5.2 与 8.1 的数据闭环逻辑	王晓芳

1. 总则

1.1 目的

本方法论旨在为 AI 应用提供一套可复现、可解释、可迭代的评测体系，覆盖评测集设计、执行、评分、分析、质量门禁、持续迭代全流程。

1.2 适用范围

- RAG 系统：制度问答、知识库问答、文档检索增强生成
- Agent 系统：任务规划、工具调用、轨迹执行
- Prompt 安全：注入攻击、越狱、间接注入

1.3 评测原则

原则	说明
可复现	相同评测集、相同模型参数、相同 Judge，结果可复现

可解释	每个得分点可追溯，reason 中必须有计算式
可迭代	评测集版本管理，评分标准可修订，模型可回归
一致性	同类行为评分方向一致，不能 A 题加分、B 题扣分
边界清晰	golden 与文档原文对齐，不引入超出文档的推断
统计可靠	关键题重复采样，区分真实短板和随机噪声

1.4 术语定义

术语	定义
golden	标准答案+评分细则+gold_chunk_ids
Judge	LLM-as-Judge，用大模型给模型回答打分
Harness	评测执行框架，基于 pytest+CI/CD
质量门禁	AI 应用上线前必须通过的评测标准
一致率	Judge 与人工评分的一致比例，目标≥85%
题型	fact/multi_hop/no_answer/ambiguous/conflict/negation
重复采样	同一题跑多次，计算均值和方差
方差	重复采样后，同题得分的离散程度

2. 评测集设计

2.1 题型分类

题型	定义	示例
fact	文档中有明确答案，直接抽取	“每月最多远程办公多少天？”
multi_hop	需要跨多条文档/多个条款推理	“连续 3 天未标记+当月违规 2 次，触发什么？”
no_answer	文档中未提及，应正确拒答	“公司是否提供子女教育补贴？”
ambiguous	文档有相关条款但边界不明确	“公司是否提供办公桌椅？”
conflict	多条文档之间存在冲突或例外	“doc_002 说 8 天，doc_006

		说不可抗力不受限”
negation	需要理解否定、例外、条件	“因设备故障延误，公司是否免责？”

2.2 文档来源与切片策略

- 来源：公司制度文档、产品手册、FAQ
- 切片：按条款/段落切片，每个 chunk 有唯一 chunk_id
- 粒度：一个 chunk 对应一个完整条款，避免跨条款切片
- 示例：doc_001~doc_007，每个 doc 对应一条制度

2.3 golden 构造规范

每条 golden 必须包含：

```
{
  "id": "Q1",
  "question": "...",
  "query_type": "fact",
  "difficulty": "easy",
  "gold_answer": "...",
  "gold_chunk_ids": ["doc_002"],
  "gold_claims": ["每月远程办公天数不超过 8 天"],
  "has_answer": true,
  "scoring": [{"point": "...", "score": 100}],
  "penalty": [{"condition": "...", "deduct": 20}]
}
```

构造要求：

- gold_answer 必须与文档原文对齐，不引入超出文档的推断。
- gold_chunk_ids 必须准确，否则 RAG 检索不到 context。
- scoring 必须可操作，每个得分点可判定“满足/不满足”。
- penalty 必须明确，什么行为扣分、扣多少。
- has_answer 标记：true/false，用于区分 no_answer 题。

2.4 难度分级

难度	定义	示例
easy	单文档、单条款、直接抽取	Q1-Q4
medium	单文档多条款，或跨 2 条文档	Q5、Q6、Q11

hard	跨 3+文档，或需要条件推理	Q9、Q12、Q15b、Q16

3. 评测执行

3.1 Harness 架构

```
ai-eval-harness/
├── datasets/
│   ├── golden-set-19.json
│   ├── corpus.json
│   ├── agent-tasks.json
│   └── injection-cases.json
├── adapters/
├── core/
├── results/
├── compare_models_rag.py
├── run.py
└── check_gate.py
```

技术栈：Python + pytest + requests + CI/CD（GitHub Actions）

3.2 模型接入规范

模型	接入方式	参数
DeepSeek	API（api.deepseek.com）	temperature=0.1, max_tokens=800
Qwen2.5:14b	Ollama（localhost:11434）	temperature=0.1, seed=42, num_predict=800

要求：

- 所有模型使用相同 temperature 和 max_tokens，保证对比公平。
- API 调用加重试机制（3 次，指数退避）。
- Judge 统一用 DeepSeek（temperature=0，response_format=json_object）。

3.3 执行流程

1. 加载 golden-set
2. 加载 corpus
3. 对每题：
   a. 根据 gold_chunk_ids 检索 context
   b. 构建 RAG prompt

c. 调用模型 A，获取回答
d. 调用 Judge，给模型 A 打分
e. 调用模型 B，获取回答
f. 调用 Judge，给模型 B 打分
g. 记录结果
4. 输出 JSONL + 汇总报告

3.4 日志与输出

- JSONL：逐题记录，含 answer、score、reason
- 汇总报告：均分、满分题数、零分题数、差距
- 输出目录：results/{timestamp}_rag-model-comparison_{models}_{dataset}/

4. 评分体系

4.1 LLM-as-Judge 设计

Judge prompt 结构：

```
【问题】{question}
【标准答案】{ground_truth}
【评分标准】{scoring}
【模型回答】{answer}

输出 JSON：{"score": 0-100, "reason": "..."}

【打分要求】
1. 逐项核对得分点，reason 中写明"得分点 X：满足/不满足，得 X 分"
2. 逐项核对扣分项，reason 中写明"扣分项 X：触发/未触发，扣 X 分"
3. score = 得分点之和 - 扣分项之和
4. reason 中必须包含计算式，格式"总分 = 50 + 30 + 20 - 0 = 100"
5. 如果 score 与计算式不一致，视为无效输出，必须重新计算
6. reason 控制在 200 字以内
7. 只输出 JSON
```

4.2 评分细则编写规范

规范	说明
得分点可判定	每个得分点必须能明确判定“满足/不满足”
分值有依据	关键点高分，次要信息低分
penalty 明确	什么行为扣分、扣多少，必须写清
内部一致	同类行为在 A 题加分，B 题也应加分
与文档对齐	不引入超出文档的推断

4.3 Judge 校准

流程：

- 构造校准集（judge-calibration-set-v1.jsonl），覆盖六种题型。
- 人工打分，作为 ground truth。
- Judge 打分，计算一致率。
- 分析不一致 case，修订 Judge prompt。
- 重复，直到一致率≥85%。

当前状态：一致率 67%→87%。

4.4 Judge 工程可靠性

Judge 调用需处理以下工程问题：

- max_tokens≥2000，防止 reason 被截断。
- JSON 容错解析：截断时尝试补全 `"` 和 `}`。
- score 与计算式数值校验：不一致时重试。
- retries≥3，失败时记录 raw output。

4.4.1 位置偏差检测

Judge 存在轻微位置偏差。对同一答案，交换“标准答案”和“模型回答”的位置，平均绝对差值 6 分（样本数 10，5 题×2 模型）。

实测数据：

- 7/10 条无偏差
- 3/10 条有偏差，幅度 10-30 分
- Q15a DeepSeek 偏差最大（-30 分）

缓解措施：

- 固定顺序：所有评测都用“标准答案在前”的顺序
- 关键题多次评测：跑 3 次，取均值
- 人工复核：偏差>20 分的题人工确认
- V1.2 计划：用不同 Judge 交叉验证

是否需要矫正：不需要。偏差幅度（6 分）小于模型差距（7.89 分），不影响选型结论。记录+缓解即可。

4.5 人工复核机制

- 抽样复核：每轮评测随机抽 10%人工复核。
- 争议复核：score 与 reason 不一致、或 score=0/100 的极端 case，人工复核。
- 校准复核：Judge prompt 修订后，用校准集验证一致率。

5. 结果分析

5.1 整体指标

指标	定义	目标
平均分	所有题得分均值	≥85
满分率	满分题数/总题数	≥50%
零分率	零分题数/总题数	≤5%
差距	模型 A 均分 - 模型 B 均分	用于选型

5.2 分题型指标

按六种题型分别统计均分，识别模型短板。

示例（本报告）：

题型	DeepSeek	Qwen	差异
fact	100	100	持平
multi_hop	85	85	持平
no_answer	86	96	Qwen 优
ambiguous	55	90	Qwen 优，DeepSeek 短板
conflict	50	100	Qwen 优，DeepSeek 严重短板
negation	90	90	持平

5.3 典型 case 分析

对以下 case 必须逐题分析：

- 零分题
- 双方差距≥40 分的题
- Judge 输出异常的题
- 评分标准有争议的题

5.4 模型对比方法

- 同评测集、同参数、同 Judge，保证公平。
- 分题型对比，识别模型风格差异。
- 定性分析，不只看分数，看回答质量。
- 区分“模型问题”和“评测集问题”，避免误判。

6. 统计可靠性

6.1 为什么需要重复采样

单次评测存在随机波动，无法区分“真实短板”和“随机噪声”。同一模型、同一题目、同 temperature，多次运行可能得到不同分数。

重复采样的目的：

- 量化波动幅度：标准差、极差。
- 区分稳定题和不稳定题。
- 区分“模型问题”和“评测集问题”。

6.2 实验设计

项	说明
重复次数	建议 3 次（关键题可 5 次）
统计指标	均值、标准差、极差
输出	逐题方差表

6.3 统计指标定义

指标	公式	说明
均值	sum(scores) / n	3 次得分平均
标准差	stdev(scores)	样本标准差
极差	max(scores) - min(scores)	最大值与最小值之差

6.4 稳定性判定

标准差	判定	处理
std = 0	稳定	单次评测足够
0 < std ≤ 20	轻微波动	多次评测取均值
std > 20	不稳定	人工复核，确认模型问题还是评测集问题

6.5 案例：Q15a/Q15b

5 题×3 次重复采样结果：

题号	DeepSeek 3 次	std	Qwen 3 次	std
Q6	100,100,100	0	80,80,80	0
Q15a	100,0,0	57.74	100,100,100	0
Q15b	0,100,0	57.74	100,100,100	0
Q16	80,80,80	0	80,80,80	0
Q18	30,30,30	0	100,100,100	0

结论：

- Q6/Q16/Q18 稳定，单次评测足够。
- Q15a/Q15b 不稳定，DeepSeek 处于能力边界。
- 修评分标准后，Qwen 从 100/70/70 稳定到 100/100/100，说明之前是评测集问题；DeepSeek 仍 100/0/0，说明是模型问题。

6.6 建议

- 正式评测中，关键题跑 3 次，取均值+标准差。
- 波动大的题（std>20），人工复核，确认是模型问题还是评测集问题。

- 把重复采样结果写入评测报告，作为模型选型的依据。

7. 评测指标

7.1 指标分类

类别	适用	指标
分类指标	fact 题	准确率、精确率、召回率、F1
生成指标	RAG	幻觉率、Faithfulness、Context Precision/Recall
评分指标	LLM-as-Judge	平均分、满分率、零分率、方差

7.2 分类指标

指标	公式	适用
准确率	(TP+TN)/(TP+TN+FP+FN)	fact 题
精确率	TP/(TP+FP)	fact 题
召回率	TP/(TP+FN)	fact 题
F1	2PR/(P+R)	fact 题

注：分类指标只适用于有明确对错的 fact 题，不适用于生成题。

7.3 生成指标

指标	定义	计算方式
幻觉率	含无依据内容的回答数/总回答数	人工标注
Faithfulness	可追溯 claim 数/回答总 claim 数	人工或 LLM 标注
Context Precision	相关 chunk 数/检索 chunk 数	需要真实检索
Context Recall	相关 chunk 数/应检索 chunk 数	需要 gold_chunk_ids

7.4 评分指标

指标	公式	适用

平均分	sum(scores)/n	Judge
满分率	满分题数/n	Judge
零分率	零分题数/n	Judge
方差	stdev(scores)	重复采样

7.5 指标计算状态

每轮评测需明确哪些指标算了、哪些没算、为什么。示例：

指标	本轮是否计算	原因
平均分	☑算了	已有数据
满分率/零分率	☑算了	已有数据
准确率/召回率/F1	☑算了（fact 题）	已有数据
幻觉率	❌没算	需人工标注
Faithfulness	部分	抽样算了，全量需人工标注
Context Precision/Recall	名义值	按 gold_chunk 精确检索，=1；真实检索 V2.0
方差	☑算了	重复采样后计算

8. 质量门禁

8.1 上线前门禁标准

场景	指标	门槛
RAG 制度问答	fact 题均分	≥95
	no_answer 均分	≥90
	conflict 均分	≥80
	整体均分	≥85
Agent 任务	任务完成率	≥90%
	异常恢复率	≥80%
	轨迹合理性（人工抽检）	≥90%
Prompt 安全	注入拦截率	≥95%
	高危泄露	0

门禁实测示例：在近期的评测中，Qwen2.5:14b 各项指标均达标（如 conflict 得分 100），顺利通过门禁；而 DeepSeek 虽然在整体均分上刚过及格线（85.79 ≥ 85），但因其在 conflict 题型上仅得 50 分（未达 80 分门槛），被门禁机制直接一票否决，拦截上线。这证明单项红线的设置能有效防止“偏科”模型进入生产环境。

8.2 门禁执行流程

1. 跑全量评测集
2. 生成评测报告
3. `check_gate.py` 自动检查
4. 通过 → 上线
5. 不通过 → 修模型/修评测集/降级上线

8.3 不通过的处理

情况	处理
单项不达标	定位短板，针对性优化
多项不达标	模型回炉，或降级上线
评测集问题	修 golden，重跑
Judge 问题	修 prompt，重新校准

9. 持续迭代

9.1 评测集版本管理

版本	变更	日期
v1.0	初版 18 题	2026-10
v1.1	Q15 拆题、Q6/Q16 评分标准修订、Q18 题型修正、Judge V1.1	2026-10-14
v1.2	Q18 评分细则调整、scoring 格式统一、新增题型	待定

9.2 评分标准修订流程

1. 发现评分标准问题（内部不一致、偏严、偏松）
2. 分析问题 case
3. 提出修订方案

4. 修订 golden
5. 重跑相关题
6. 对比修订前后
7. 更新版本

9.3 模型迭代回归

- 模型更新后，跑全量评测集。
- 对比上一版模型分数。
- 如果分数下降，定位原因。
- 更新质量门禁标准。

10. 附录

10.1 模板：golden 编写模板

```
{
  "id": "QXX",
  "question": "...",
  "query_type": "fact|multi_hop|no_answer|ambiguous|conflict|negation",
  "difficulty": "easy|medium|hard",
  "gold_answer": "...",
  "gold_chunk_ids": ["doc_XXX"],
  "gold_claims": ["..."],
  "has_answer": true,
  "scoring": [{"point": "...", "score": 100}],
  "penalty": [{"condition": "...", "deduct": 20}]
}
```

10.2 模板：评分细则模板

```
{
  "scoring": [
    {"point": "得分点 1 描述", "score": 50},
    {"point": "得分点 2 描述", "score": 30},
    {"point": "得分点 3 描述", "score": 20}
  ],
  "penalty": [
    {"condition": "扣分条件 1", "deduct": 20}
  ]
}
```

10.3 模板：评测报告模板

1. 摘要
2. 评测结果
   2.1 整体数据

2.2 分题型数据
2.3 典型 case
3. 发现的问题
4. 修订方案
5. 修订后重跑结果
6. 结论与下一步
附录：逐题数据

10.4 案例：18 题 RAG 评测

见以下报告：

- 《RAG 评测集优化报告 V1.0》——18 题对比评测、评测集修订、Judge V1.1
- 《重复采样分析报告 V1.0》——5 题×3 次方差分析
- 《评测指标计算报告 V1.0》——指标定义与计算示例

核心数据：

- 首轮：DeepSeek 82.35，Qwen 86.11（来源：RAG 报告）
- 修订后 19 题：DeepSeek 85.79，Qwen 93.68（来源：RAG 报告）
- Judge 一致率：67%→87%（来源：RAG 报告）
- 重复采样：Q15a/Q15b DeepSeek std=57.74，Qwen std=0（来源：重复采样报告）
- 关键发现：Q15b（程序条件推理）和 Q18（边界推理）是 DeepSeek 短板（来源：RAG 报告+重复采样报告）

10.5 资产清单

资产	文件	用途
RAG 评测集	golden-set-19.json	制度问答评测
Agent 评测集	agent-tasks.json	轨迹+异常注入
安全评测集	injection-cases.json	Prompt 注入
Judge 校准集	judge-calibration-set-v1.jsonl	Judge 一致性
Harness	pytest 框架	执行+CI
质量门禁	check_gate.py	上线标准

方法论结束。

后续：

- 将本方法论用于 Agent 评测和安全测试。

配套文档：

- 《RAG 评测集优化报告》——RAG 评测完整案例
- 《重复采样分析报告》——5 题×3 次方差分析
- 《评测指标计算报告》——指标定义与计算示例

王晓芳丨AI测试评测丨2026-10