RAG 评测集优化报告 V1.1

报告日期：2026 年 10 月 14 日

评测集版本：golden-set-19 v1.0 → v1.1

评测对象：DeepSeek vs Qwen2.5:14b

评测方式：LLM-as-Judge（Judge V1.0 → V1.1）

报告人：王晓芳

王晓芳 | AI测试评测 | 2026-10

目录

1. 摘要 3

2. 首轮评测结果 3

2.1 整体数据 3

2.2 分题型数据（首轮） 4

2.3 典型 case 4

Q15（conflict）——双方共同短板 4

Q9（negation）——评分标准矛盾 4

3. 发现的问题 5

3.1 Q15：golden 与文档原文不对齐 5

3.2 Q6/Q16：评分标准内部不一致 5

3.3 Q18：题型标签错误 5

3.4 Judge 输出 score/reason 不一致 5

4. 修订方案 6

4.1 golden 修订 6
4.2 评分细则修订 6
4.3 字段补全 6
4.4 Judge prompt 修订（V1.0 → V1.1） 6
5. 修订后重跑结果 7
5.1 逐题结果 7
5.2 对比表：首轮 vs 修订后 7
5.3 修订后 19 题整体数据 8
6. 结论与下一步 8
6.1 评测集 V1.1 可用性判断 8
6.2 模型选型建议 8
6.3 遗留问题（V1.2 待办） 9
6.4 下一轮全量评测计划 9
附录：19 题逐题数据 9

王晓秀 | AI测试评测 | 2026-10

1. 摘要

本轮评测对 18 道公司制度 RAG 题进行对比测试，覆盖 fact、multi_hop、no_answer、ambiguous、conflict、negation 六种题型。首轮结果：Qwen2.5:14b 平均 86.11 分，DeepSeek 平均 82.35 分。

首轮评测暴露了 4 类评测集自身问题：

- Q15 golden 与文档原文不对齐：标准答案要求“不违规”，但文档原文包含“人力资源部另行通知”的程序条件，导致严谨回答被判 0 分。
- Q6/Q16 评分标准内部不一致：同一类行为（指出文档未明确）在 Q6 被扣分，在 Q16 未指出也被扣分。
- Q18 题型标签错误：归为 no_answer，但得分点包含“设备自备”的边界推理，应归为 ambiguous。
- Judge 输出 score/reason 不一致：Q16 DeepSeek 出现 score=100 但 reason 写“得 80 分”。

修订后（golden v1.1 + Judge V1.1）重跑 5 题，评测集升级至 v1.1。修订后 19 题均分：Qwen 93.68，DeepSeek 85.79，Qwen 领先 7.89 分。

本报告记录问题发现、修订方案、重跑结果，并给出模型选型建议。

2. 首轮评测结果

2.1 整体数据

指标	DeepSeek	Qwen2.5:14b
平均分	82.35	86.11
满分题数	9	10
零分题	1（Q15）	0
最低分	0（Q15）	30（Q15）
高分题（≥90）	9	9
中分题（60-89）	7	8
低分题（<60）	2	1

2.2 分题型数据（首轮）

题型	题号	DeepSeek 均分	Qwen 均分	差异
fact	Q1-Q4、Q7、Q13、Q14	100	100	持平
multi_hop	Q5、Q9、Q12、Q16	90	85	DeepSeek 优
no_answer	Q7、Q13、Q14、Q17、Q18	86	96	Qwen 优
ambiguous	Q11	80	80	持平
conflict	Q15	0	30	都差
negation	Q6、Q8、Q10	76.7	73.3	DeepSeek 优

2.3 典型 case

Q15（conflict）——双方共同短板

- 标准答案：不违规。
- DeepSeek 回答：以“人力资源部是否另行通知”为条件，最终说“无法直接判定”，得 0 分。
- Qwen 回答：同样以“是否发布临时通知”为条件，但提到“不可抗力”和“不受第二条限制”，得 30 分。

问题定性：文档 doc_006 原文确实写了“临时政策由人力资源部另行通知”。模型要求“通知”才不违规，比标准答案更严谨。这是评测集问题，不是模型问题。

Q6（negation）——评分标准矛盾

- DeepSeek 回答：“视为旷工+文档未明确具体处理”，得 50 分。
- 评分 reason：“出现‘无法确定’等表述，扣 20 分。”
- 但 Q8/Q11/Q12 中，“谨慎指出文档未明确”是加分项。同一类行为，评分方向相反。

3. 发现的问题

3.1 Q15：golden 与文档原文不对齐

文档原文：

- doc_002 第二条：每月远程办公天数不超过 8 天。
- doc_006 第六条：因疫情、自然灾害等不可抗力，公司可临时调整远程办公政策，不受第二条限制。临时政策由人力资源部另行通知。

标准答案：“不违规，因为暴雨属于不可抗力，不受第二条限制。”

问题：标准答案忽略了“人力资源部另行通知”这一程序条件。模型答“取决于是否通知”是更严谨的，却被判 0 分。golden 与原文不对齐，导致评测结果失真。

3.2 Q6/Q16：评分标准内部不一致

题号	模型行为	首轮评分	问题
Q6	指出“文档未明确”	扣 20 分	与 Q8/Q11/Q12 加分逻辑矛盾
Q16	未指出“文档未明确”	扣 20 分	与 Q6 扣分逻辑矛盾

结论：同一类行为（指出文档未明确），在 Q6 被惩罚，在 Q16 未做也被惩罚。评分标准内部不一致，导致模型得分无法横向比较。

3.3 Q18：题型标签错误

现状：归为 no_answer，标准答案“文档未提及”，但评分细则包含“设备由员工自备”得分点。

问题：“办公桌椅是否属于设备”是边界推理，属于 ambiguous，不是纯 no_answer。题型标签错误导致分题型统计失真。

3.4 Judge 输出 score/reason 不一致

Q16 DeepSeek 首轮：score=100，但 reason 写“未明确指出，扣 20 分，得 80 分”。

问题：Judge 自己算错了，score 和 reason 矛盾。这导致首轮 Q16 DeepSeek 的 100 分不可信，真实分应为 80。

4. 修订方案

4.1 golden 修订

题号	修订动作	修订后
Q15	拆为 Q15a（考原则）和 Q15b（考程序）	Q15a 答案“不违规”；Q15b 答案“违规，因通知未发布”
Q18	题型从 no_answer 改为 ambiguous	答案加“办公桌椅是否属于设备文档未明确”

4.2 评分细则修订

题号	修订动作
Q6	“指出文档未明确”从扣 20 分改为加 20 分；强行断言扣 20 分
Q16	增加“指出文档未明确”加 20 分；强行断言扣 20 分
Q15a	新增：拒绝给明确结论扣 20 分
Q15b	新增：忽略程序条件扣 30 分
Q18	新增：直接断言不提供扣 20 分

4.3 字段补全

18 题补全 query_type 和 difficulty，新题补 gold_chunk_ids、gold_claims、has_answer。字段统一为：id / question / query_type / difficulty / gold_answer / gold_chunk_ids / gold_claims / has_answer / scoring。

4.4 Judge prompt 修订（V1.0 → V1.1）

新增 5 条打分要求：

- 逐项核对得分点，reason 中写明“得分点 X：满足/不满足，得 X 分”。

- 逐项核对扣分项，reason 中写明“扣分项 X：触发/未触发，扣 X 分”。
- score 必须等于“得分点之和 - 扣分项之和”。
- reason 中必须包含计算式，格式如“总分 = 50 + 30 + 20 - 0 = 100”。
- 如果 score 与计算式不一致，视为无效输出，必须重新计算。

5. 修订后重跑结果

说明：重跑使用相同模型、相同 Harness，仅替换 golden（v1.1）和 Judge prompt（V1.1）。重跑 5 题：Q6、Q15a、Q15b、Q16、Q18。

5.1 逐题结果

题号	DeepSeek	Qwen	说明
Q6	100	100	双方都答全 3 个点
Q15a	100	100	双方都答全
Q15b	0	100	DeepSeek 拒答，Qwen 答对
Q16	80	80	双方都缺“文档未明确叠加”
Q18	30	100	DeepSeek 只答“未提及”，Qwen 答全
5 题均分	62.0	96.0	Qwen 领先 34 分

说明：本轮重跑使用 Judge V1.1，所有题目 score 与 reason 中的计算式一致，评分可复核。相比 Judge V1.0（Q16 DeepSeek 出现 score=100/reason=80 的矛盾），Judge V1.1 的一致性问题已修复。

5.2 对比表：首轮 vs 修订后

题号	首轮 DeepSeek	首轮 Qwen	修订后 DeepSeek	修订后 Qwen	变化说明
Q6	50	60	100	100	评分标准修订，双方涨
Q15a	0（原 Q15）	30（原 Q15）	100	100	拆题+golden 修订
Q15b	—	—	0	100	新增题，

					DeepSeek 崩
Q16	100（Judge 误算）	80	80	80	Judge 修复
Q18	30	80	30	100	题型改 ambiguous

5.3 修订后 19 题整体数据

指标	DeepSeek	Qwen2.5:14b
14 题首轮总分	1320	1300
5 题修订后总分	310	480
19 题总分	1630	1780
19 题均分	85.79	93.68
差距	—	Qwen 领先 7.89

6. 结论与下一步

6.1 评测集 V1.1 可用性判断

修订后，评测集 V1.1 解决了 4 类问题：

- Q15 拆题后，conflict 题型可用，不再因 golden 问题误判模型。
- Q6/Q16 评分标准统一，同类行为评分方向一致。
- Q18 题型归类修正，分题型统计准确。
- Judge V1.1 修复 score/reason 不一致，评分可复核。

结论：V1.1 可用于正式模型选型和回归评测。

6.2 模型选型建议

- Qwen2.5:14b：整体更均衡，no_answer、ambiguous、conflict 处理更稳，适合作为制度问答主模型。
- DeepSeek：fact 和 multi_hop 更强，但 conflict 题容易陷入“文档未明确即拒答”，适合作为辅助或特定场景模型。

- 关键差异点：Q15b（程序条件判断）和 Q18（边界推理）是 DeepSeek 的短板，Qwen 在这两类题上明显更优。
- 建议：制度问答场景优先 Qwen2.5:14b；若需多跳推理，可对比 DeepSeek 在 Q15a/Q15b 重跑后的表现。

6.3 遗留问题（V1.2 待办）

问题	说明	优先级
Q18 评分细则偏严	“设备自备”作为必得分点，DeepSeek 答“未提及”只拿 30 分。建议改为加分项，或提高第一点分值。	P1
scoring 字段格式不统一	老题 scoring 是字符串，新题是数组。建议 V1.2 统一为数组结构。	P2
新增 conflict/negation/ambiguous 题	每类增加 2-3 道，提升题型平衡。	P2
Judge 校准集扩充	覆盖六种题型，目标一致率 ≥85%。	P2

6.4 下一轮全量评测计划

事项	说明
评测集版本	golden-set-19 v1.2（含 Q18 评分细则修订）
重跑范围	全量 19 题
模型	DeepSeek、Qwen2.5:14b，可增加新模型
Judge	Judge V1.1，一致率≥85%
输出	全量对比报告，更新质量门禁

附录：19 题逐题数据

题号	题型	难度	DeepSeek	Qwen	备注
Q1	fact	easy	100	100	—
Q2	fact	easy	100	100	—

Q3	fact	easy	100	100	—
Q4	fact	easy	100	100	—
Q5	multi_hop	medium	90	90	—
Q6	negation	medium	100	100	评分标准修订
Q7	no_answer	easy	100	100	—
Q8	ambiguous	medium	80	60	Qwen 过度推断
Q9	multi_hop	hard	90	90	—
Q10	conflict	medium	100	100	—
Q11	negation	medium	80	80	—
Q12	multi_hop	hard	80	80	—
Q13	no_answer	easy	100	100	—
Q14	no_answer	easy	100	100	—
Q15a	conflict	medium	100	100	拆题后新增
Q15b	conflict	hard	0	100	拆题后新增，DeepSeek 短板
Q16	multi_hop	hard	80	80	Judge 修复
Q17	ambiguous	easy	100	100	—
Q18	ambiguous	medium	30	100	评分细则偏严，V1.2 调

王晓芳 | AI测试评测 | 2026-10

报告结束。

配套文档：《AI 评测体系方法论》——本报告结论已整合进第 4 章“评分体系”和第 9 章“持续迭代”。