重复采样分析报告 V1.0

报告日期：2026 年 10 月 14 日

评测集版本：golden-set-18 v1.1

评测对象：DeepSeek vs Qwen2.5:14b

评测方式：LLM-as-Judge（Judge V1.2）

报告人：王晓芳

王晓芳 | AI测试评测 | 2026-10

目录

1. 摘要 3

2. 实验设计 3

3. 结果数据 4

3.1 逐题方差表 4

3.2 整体均分（按所有 repeat 平均） 4

4. 分析 4

4.1 稳定题（std=0） 4

4.2 不稳定题（std>0） 5

Q15a：DeepSeek 100/0/0 5

Q15b：DeepSeek 0/100/0 5

4.3 评分标准修正的影响（Q15a） 5

5. 对模型选型的影响 6

6. 结论 7

7. 下一步 7

附录：逐题完整数据 7

Q6 7

Q15a 8

Q15b 8

Q16 8

Q18 8

王晓芳丨AI测试评测丨2026-10

1. 摘要

单次评测存在随机波动，无法区分“真实短板”和“随机噪声”。本报告通过重复采样（同一题跑 3 次），对 5 道题（Q6、Q15a、Q15b、Q16、Q18）进行方差分析。

核心发现：

- 3 道稳定题（std=0）：Q6、Q16、Q18——单次评测足够。
- 2 道不稳定题（std=57.74）：Q15a、Q15b——必须多次评测。
- Q15a 的“波动”是模型问题：修评分标准后，Qwen 从 100/70/70 稳定到 100/100/100，DeepSeek 仍 100/0/0。
- Q15b 的“波动”是模型问题：DeepSeek 0/100/0，处于能力边界。
- Qwen 在 conflict 题型上稳定满分，DeepSeek 不稳定。

对模型选型的影响：Qwen 适合制度问答；DeepSeek 不适合处理“程序条件推理”和“冲突条款”类问题。

2. 实验设计

项	说明
题目	Q6、Q15a、Q15b、Q16、Q18
重复次数	3
模型	DeepSeek、Qwen2.5:14b
Judge	Judge V1.2（含 score/reason 一致性校验）
总运行次数	5 题 × 3 次 × 2 模型 = 30 次
输出指标	均值、标准差、极差

统计方法：

- 均值 = 3 次得分之和 / 3
- 标准差 = statistics.stdev(scores)（样本标准差）
- 极差 = max(scores) - min(scores)

3. 结果数据

3.1 逐题方差表

题号	DeepSeek 3 次	均值	标准差	极差	Qwen 3 次	均值	标准差	极差
Q6	100,100,100	100	0	0	80,80,80	80	0	0
Q15a	100,0,0	33.33	57.74	100	100,100,100	100	0	0
Q15b	0,100,0	33.33	57.74	100	100,100,100	100	0	0
Q16	80,80,80	80	0	0	80,80,80	80	0	0
Q18	30,30,30	30	0	0	100,100,100	100	0	0

3.2 整体均分（按所有 repeat 平均）

模型	均分	说明
DeepSeek	55.33	受 Q15a/Q15b 波动拖累
Qwen	92.0	稳定
差距	-36.67	Qwen 领先

4. 分析

4.1 稳定题（std=0）

Q6、Q16、Q18 三道题，双方 3 次得分完全一致，标准差为 0。

题号	题型	DeepSeek	Qwen	说明
Q6	negation	100	80	DeepSeek 稳定强，Qwen 稳定中
Q16	multi_hop	80	80	双方都缺“文档未明确叠加”得分点
Q18	ambiguous	30	100	DeepSeek 只答“未提及”，Qwen 答全

结论：这三道题单次评测足够，不需要重复采样。

4.2 不稳定题（std>0）

Q15a、Q15b 两道题，DeepSeek 标准差均为 57.74，极差 100。

Q15a：DeepSeek 100/0/0

repeat	回答第一句	得分
0	“不违反‘每月不超过 8 天’的规定”	100
1	“取决于人力资源部是否已发布通知……无法直接判定”	0
2	“取决于人力资源部是否已发布通知……仍应适用第二条”	0

三次回答的推理逻辑几乎一样（都提到不可抗力、人力资源部通知），但结论表述不同：repeat 0 直接下结论“不违反”；repeat 1/2 给条件性结论“取决于通知”，拒答。

性质：结论不稳定。模型“敢不敢下结论”不稳定。

Q15b：DeepSeek 0/100/0

repeat	回答关键句	得分
0	“文档中未提及……无法依据文档判断是否违规”	0
1	“临时政策并未生效……属于违规”	100
2	“文档中未提及……无法基于文档判断”	0

性质：推理不稳定。模型“能不能推出结论”不稳定。

4.3 评分标准修正的影响（Q15a）

修评分标准前：

模型	3 次	均值	标准差
DeepSeek	0,100,100	66.67	57.74

Qwen	100,70,70	80	17.32

修评分标准后：

模型	3 次	均值	标准差
DeepSeek	100,0,0	33.33	57.74
Qwen	100,100,100	100	0

关键结论：

- Qwen 从波动变稳定：100/70/70 → 100/100/100。说明之前的波动是评分标准对“并不一定违反”判定不清导致的，不是模型问题。
- DeepSeek 仍不稳定：0/100/100 → 100/0/0。说明 DeepSeek 的波动是模型问题，不是评分标准问题。

这个实验证明了“修评分标准”能区分“评测集问题”和“模型问题”。

5. 对模型选型的影响

场景	推荐模型	理由
制度问答（fact/no_answer）	Qwen 或 DeepSeek	双方稳定
多跳推理（multi_hop）	双方均可	Q16 双方稳定 80
冲突条款（conflict）	Qwen	Qwen 稳定满分，DeepSeek 不稳定
程序条件推理	Qwen	Q15b DeepSeek 0/100/0，不可靠
边界推理（ambiguous）	Qwen	Q18 DeepSeek 30，Qwen 100

结论：

- Qwen2.5:14b：整体稳定，适合制度问答主模型。
- DeepSeek：fact 和 multi_hop 稳定，但 conflict 题型不稳定，不适合生产环境处理“程序条件推理”和“冲突条款”类问题。

6. 结论

- 重复采样是评测体系的必要环节。单次评测无法区分“真实短板”和“随机噪声”。
- 5 题中 3 题稳定，2 题不稳定。稳定题单次评测足够，不稳定题必须多次评测。
- Q15a 和 Q15b 是 DeepSeek 的能力边界题。Q15a 是“结论不稳定”，Q15b 是“推理不稳定”。
- Qwen 在 conflict 题型上稳定满分，适合制度问答。
- 修评分标准能区分“评测集问题”和“模型问题”。Q15a 修评分标准后，Qwen 稳定，DeepSeek 仍不稳定。
- Judge V1.2 一致性通过。所有题目 score 与 reason 计算式一致，评分可复核。

建议：

- 正式评测中，关键题跑 3 次，取均值+标准差。
- 波动大的题（std>20），人工复核，确认是模型问题还是评测集问题。
- 把重复采样写入《AI 评测体系方法论》V1.1。

7. 下一步

事项	说明
全量 19 题跑 3 次	建立方差基线，识别所有不稳定题
修 Q15a/Q15b 评分标准	如果波动持续，需进一步分析
把重复采样写入方法论 V1.1	新增“统计可靠性”章节
扩大量化指标	增加置信区间、t 检验

附录：逐题完整数据

Q6

repeat	DeepSeek	Qwen
0	100	80
1	100	80
2	100	80

Q15a

repeat	DeepSeek	Qwen
0	100	100
1	0	100
2	0	100

Q15b

repeat	DeepSeek	Qwen
0	0	100
1	100	100
2	0	100

Q16

repeat	DeepSeek	Qwen
0	80	80
1	80	80
2	80	80

Q18

repeat	DeepSeek	Qwen
0	30	100
1	30	100
2	30	100

报告结束。

配套文档：《AI 评测体系方法论 V1.1》——本报告结论已整合进第 6 章“统计可靠性”。