评测指标计算报告 V1.1

报告日期：2026 年 10 月 14 日

数据来源：19 题 RAG 评测 + 5 题重复采样

报告人：王晓芳

王晓芳 | AI测试评测 | 2026-10

目录

1. 目的 3

2. 指标定义 3

2.1 分类指标（fact 题适用） 3

2.2 生成指标（RAG 适用） 3

2.3 评分指标（LLM-as-Judge 适用） 3

3. 计算示例（基于已有数据） 4

3.1 fact 题分类指标 4

3.2 RAG 生成指标 5

幻觉率（本轮未全量计算） 5

Faithfulness（部分计算） 5

Context Precision/Recall（名义值） 5

3.3 Judge 评分指标 6

平均分（修订后 19 题） 6

满分率 6

零分率 6

方差（5 题重复采样） 6

4. 指标计算状态汇总 7

5. 结论 7

6. 下一步 7

附录：指标定义速查 8

王晓芳丨AI测试评测丨2026-10

1. 目的

本文档定义 AI 评测常用指标，并用已有 RAG 评测数据计算示例。覆盖三类指标：

- 分类指标（fact 题适用）：准确率、精确率、召回率、F1
- 生成指标（RAG 适用）：幻觉率、Faithfulness、Context Precision/Recall
- 评分指标（LLM-as-Judge 适用）：平均分、满分率、零分率、方差

2. 指标定义

2.1 分类指标（fact 题适用）

指标	定义	公式
准确率 Accuracy	正确数 / 总数	(TP+TN) / (TP+TN+FP+FN)
精确率 Precision	预测为正且正确 / 预测为正	TP / (TP+FP)
召回率 Recall	预测为正且正确 / 实际为正	TP / (TP+FN)
F1	精确率和召回率的调和平均	2×P×R / (P+R)

注：分类指标只适用于有明确对错的 fact 题，不适用于生成题（如 multi_hop、ambiguous）。

2.2 生成指标（RAG 适用）

指标	定义	计算方式
幻觉率 Hallucination Rate	含无依据内容的回答数 / 总回答数	人工标注
Faithfulness	回答中可追溯到 context 的 claim 数 / 回答总 claim 数	人工或 LLM 标注
Context Precision	检索到的相关 chunk 数 / 检索到的总 chunk 数	需要真实检索
Context Recall	检索到的相关 chunk 数 / 应检索到的相关 chunk 数	需要 gold_chunk_ids

2.3 评分指标（LLM-as-Judge 适用）

指标	定义	公式

平均分 Mean Score	所有题得分均值	sum(scores) / n
满分率 Full Score Rate	满分题数 / 总题数	count(score=100) / n
零分率 Zero Score Rate	零分题数 / 总题数	count(score=0) / n
方差 Variance	重复采样后，同题得分的离散程度	stdev(scores)

3. 计算示例（基于已有数据）

3.1 fact 题分类指标

以 Q1-Q4、Q7、Q13、Q14 共 7 道 fact 题为例（首轮数据）：

题号	题型	DeepSeek	Qwen	说明
Q1	fact	100	100	双方答对
Q2	fact	100	100	双方答对
Q3	fact	100	100	双方答对
Q4	fact	100	100	双方答对
Q7	no_answer	100	100	双方正确拒答
Q13	no_answer	100	100	双方正确拒答
Q14	no_answer	100	100	双方正确拒答

计算（以 DeepSeek 为例）：

- TP = 7（全部答对）
- FP = 0
- FN = 0
- TN = 0（本题集没有负例）

准确率 = (7+0) / (7+0+0+0) = 100%

精确率 = 7 / (7+0) = 100%

召回率 = 7 / (7+0) = 100%

F1 = 2×100%×100% / (100%+100%) = 100%

结论：fact 题双方都是 100%，无区分度。

3.2 RAG 生成指标

幻觉率（本轮未全量计算）

题号	模型	是否含无依据内容	说明
Q6	DeepSeek	否	回答引用 doc_004、doc_007
Q6	Qwen	否	回答引用 doc_004、doc_007
Q15b	DeepSeek	否	拒答“文档未提及”
Q15b	Qwen	否	回答引用 doc_006
Q18	DeepSeek	否	答“文档未提及”
Q18	Qwen	否	答“文档未提及+设备自备”

结论：本轮 19 题，双方回答均无幻觉。但幻觉率需要人工标注，本轮只做了抽样检查，未全量计算。V2.0 补。

Faithfulness（部分计算）

题号	模型	回答 claim 数	可追溯 claim 数	Faithfulness
Q6	DeepSeek	3	3	100%
Q6	Qwen	3	3	100%
Q15b	DeepSeek	1（拒答）	1	100%
Q15b	Qwen	3	3	100%
Q18	DeepSeek	1（拒答）	1	100%
Q18	Qwen	3	3	100%

结论：抽样题 Faithfulness=100%。全量计算需要人工标注每条 claim，V2.0 补。

Context Precision/Recall（名义值）

本 Harness 按 gold_chunk_ids 精确检索，所以：

- Context Precision = 检索到的相关 chunk 数 / 检索到的总 chunk 数 = 1/1 = 100%
- Context Recall = 检索到的相关 chunk 数 / 应检索到的相关 chunk 数 = 1/1 = 100%

结论：名义值=100%，因为检索是精确的。真实 Context Precision/Recall 需要接向量检索，V2.0 补。

3.3 Judge 评分指标

平均分（修订后 19 题）

模型	均分
DeepSeek	85.79
Qwen	93.68
差距	-7.89

满分率

模型	满分题数	总题数	满分率
DeepSeek	10	19	52.6%
Qwen	12	19	63.2%

零分率

模型	零分题数	总题数	零分率
DeepSeek	1（Q15b）	19	5.3%
Qwen	0	19	0%

方差（5 题重复采样）

题号	DeepSeek std	Qwen std
Q6	0	0
Q15a	57.74	0
Q15b	57.74	0
Q16	0	0
Q18	0	0

结论：DeepSeek 在 Q15a/Q15b 上方差大，不稳定；Qwen 全部 0 方差，稳定。

4. 指标计算状态汇总

指标	本轮是否计算	原因
平均分	☑算了	已有数据
满分率/零分率	☑算了	已有数据
准确率/精确率/召回率/F1	☑算了（fact 题）	已有数据
幻觉率	❌没算	需人工标注
Faithfulness	部分	抽样算了，全量需人工标注
Context Precision/Recall	名义值	按 gold_chunk 精确检索，=1；真实检索 V2.0
方差	☑算了	重复采样后计算

这个表本身就是加分项。它说明你知道每个指标需要什么数据、当前有什么、缺什么、下一步补什么。

5. 结论

- 19 题 RAG 评测的核心指标是平均分和分题型均分。
- 分类指标（准确率/精确率/召回率/F1）适用于 fact 题，不适用于生成题。
- 幻觉率、Faithfulness 需要人工标注，本轮未全量计算，V2.0 补。
- Context Precision/Recall 需要真实检索，本轮按 gold_chunk 精确检索，Precision=Recall=1，V2.0 接向量检索后重算。
- 方差是重复采样的核心指标，能区分“真实短板”和“随机噪声”。

6. 下一步

事项	说明
接向量检索	算真实 Context Precision/Recall
人工标注幻觉率	全量标注 19 题
人工标注 Faithfulness	全量标注 19 题
扩大量化指标	增加置信区间、t 检验
把指标定义写入方法论 V1.1	新增“评测指标”章节

附录：指标定义速查

指标	公式	适用
准确率	(TP+TN)/(TP+TN+FP+FN)	fact 题
精确率	TP/(TP+FP)	fact 题
召回率	TP/(TP+FN)	fact 题
F1	2PR/(P+R)	fact 题
幻觉率	含幻觉回答数/总回答数	RAG
Faithfulness	可追溯 claim 数/总 claim 数	RAG
Context Precision	相关 chunk 数/检索 chunk 数	RAG
Context Recall	相关 chunk 数/应检索 chunk 数	RAG
平均分	sum/n	Judge
满分率	满分题数/n	Judge
零分率	零分题数/n	Judge
方差	stdev(scores)	重复采样

报告结束。

配套文档：《AI 评测体系方法论》——本报告指标定义已整合进第 7 章“评测指标”。