LLM 评测能力对比报告（30 题）

报告日期：2026 年 10 月

评测对象：DeepSeek-Chat（API）vs Qwen2.5:14b（本地 Ollama）

评测方式：LLM-as-Judge

报告人：王晓芳

目录

一、评测目标与方法 3

1.1 目标 3

1.2 方法 3

二、Golden Set 设计 3

2.1 分类分布 3

2.2 难度分布 4

2.3 题型设计特点 4

三、评测结果 4

3.1 整体对比 4

3.2 按分类对比 4

3.3 按难度对比 5

四、失败模式分析 5

4.1 分数分档 5

4.2 失败类型分布 6

王晓芳 | AI测试评测 | 2026-10

4.3 三类失败的典型样例 7
类型一：通用套话（27%）——最普遍 7
类型二：知识缺失+瞎编（17%） 7
类型三：知识不完整（40%）——最大类 7
五、根因分析 8
5.1 知识时效性（17%失败） 8
5.2 领域深度不足（40%失败） 8
5.3 通用套话倾向（27%失败） 8
六、结论 9
6.1 核心结论 9
6.2 失败特征 9
6.3 适用建议 9
七、方法论反思 10
7.1 本次评测的有效性 10
7.2 发现的问题及修正 10
7.3 可改进方向 11
八、附录 11
8.1 数据文件清单 11

王晓秀 | AI测试评测 | 2026-10

一、评测目标与方法

1.1 目标

验证通用大语言模型在“LLM 评测方法论”这一专业领域的知识水平，并对比：

- 在线 API 强模型（DeepSeek-Chat）
- 本地部署中等模型（Qwen2.5:14b）

1.2 方法

采用 LLM-as-Judge 评分范式，流程如下：

Golden Set（30 题）→ 被测模型作答（DeepSeek/Qwen2.5:14b）→ Judge 模型按评分标准打分（DeepSeek-Chat，temperature=0）→ 汇总报告 + 失败模式分析

关键设计：

环节	设计
题集	30 条，覆盖 6 个领域分类、3 个难度层级
Prompt	统一模板，明确锁定“LLM 评测方法论”领域
被测模型	DeepSeek-Chat（API）+ Qwen2.5:14b（本地）
Judge	DeepSeek-Chat，temperature=0，逐项核对评分标准
评分	0-100 分，每题有明确评分点和分值

二、Golden Set 设计

2.1 分类分布

分类	条数	说明
基础概念	5	LLM 测试 vs 传统测试、幻觉、上下文污染等
LLM 测试核心	6	LLM-as-Judge、Judge 校准、Agent 测试等
Agent 与协议	5	MCP、SWE-bench、GAIA、AgentBench 等

评测集与评分	2	评测集构建、评分标准设计
安全与合规	5	提示注入、越狱、数据泄露、Guardrails、红队
工程实践	7	LLM 生成用例、混合 Judge、AI 提效落地等

2.2 难度分布

难度	条数
基础	15
进阶	11
高级	4

2.3 题型设计特点

- 术语精确性：每题有明确评分点和分值，Judge 逐项核对
- 领域专用性：覆盖 LLM 评测领域的核心术语（MCP、上下文污染、LLM-as-Judge 等）
- 时效性：包含 2023-2024 年提出的新概念（MCP、SWE-bench、GAIA）

三、评测结果

3.1 整体对比

模型	均分	排名
DeepSeek-Chat	85.7	1
Qwen2.5:14b	28.2	2

结论：差距 57.5，本地 14B 模型得分仅为 API 强模型的 1/3。

3.2 按分类对比

分类	DeepSeek	Qwen14b	差距
基础概念	79.0	38.0	-41.0
LLM 测试核心	91.7	30.0	-61.7
Agent 与协议	99.0	8.0	-91.0

评测集与评分	50.0	10.0	-40.0
安全与合规	99.0	35.0	-64.0
工程实践	76.4	34.3	-42.1

注：「评测集与评分」分类仅 2 条题，样本量过小，均值差异（-40）仅供参考，不作为独立结论。

关键发现：

- Agent 与协议类差距最大（-91）：Qwen14b 几乎全军覆没
- 评测集与评分类差距第二（-40）：两条题只得 10 分（样本量小，仅供参考）
- 基础概念类差距最小（-41）：但 Qwen14b 也只有 38 分

3.3 按难度对比

难度	DeepSeek	Qwen14b
基础	90.3	27.3
进阶	83.2	25.9
高级	75.0	37.5

关键发现：

- DeepSeek 得分随难度递减（90→83→75），符合预期
- Qwen14b 难度曲线异常（27.3→25.9→37.5），高级题反而得分最高

原因是：高级题样本少（4 条），统计意义弱；且 Qwen14b 在高级题上的“通用套话”恰好碰对了一些评分点。

注：当前题集共 30 条，各分类/难度样本量偏小（最少 2 条，最多 15 条）。若要有效观察难度曲线和分类差异，下一版建议每个难度层级至少 10 条，每个分类至少 8-10 条，总量扩大到 80-100 条。

四、失败模式分析

4.1 分数分档

分档	条数	占比	id 列表

完全正确（70-100）	2	7%	GS-004、GS-024
部分正确（40-69）	12	40%	GS-002、005、007、009、010、016、020、021、022、027、028、029
通用套话/边缘（20-39）	3	10%	GS-011、018、026
严重失败（0-19）	13	43%	GS-001、003、006、008、012、013、014、015、017、019、023、025、030

4.2 失败类型分布

失败类型	数量	占比	典型 id
通用套话（答对但不对题）	8	27%	GS-001、003、006、008、017、023、025、030
知识缺失（不知道/瞎编）	5	17%	GS-012、013、014、015、019
知识不完整（答对一半，缺细节）	12	40%	GS-002、005、007、009、010、016、020、021、022、027、028、029
术语误解（理解成另一个概念）	2	7%	GS-019、GS-021（旧题）
完全正确	2	7%	GS-004、GS-024
其他	1	3%	GS-011

4.3 三类失败的典型样例

类型一：通用套话（27%）——最普遍

GS-001「LLM 测试和传统软件测试最大的区别是什么？」

期望答案：传统测试测试确定性，断言可写死；LLM 测试测试不确定性，需要轨迹验证+评分+多次统计

Qwen14b 答：“测试对象和目标不同。传统测试关注代码正确性、性能，LLM 测试关注文本质量、理解能力、知识时效性……”

问题：答的是“LLM 特点”而非“测试视角下的区别”，核心的“确定性 vs 不确定性”没提

GS-003「LLM 测试的四个核心难点是什么？」

期望答案：非确定性、幻觉、上下文污染、安全边界

Qwen14b 答：评估标准主观性、全面性、公平比较、伦理隐私

问题：答的是“任何评测都有的挑战”，不是“LLM 特有的难点”

特征：答案本身没错，但答不对题——模型用“通用最佳实践”套专业问题。

类型二：知识缺失+瞎编（17%）

GS-012「MCP 是什么？」

期望答案：Model Context Protocol，模型上下文协议，让大模型用统一标准连接外部工具和数据源

Qwen14b 答：“MCP（Model Confidence Penalty）是一种评估大语言模型输出可靠性的方法……”

问题：全称完全错误，概念凭空虚构

GS-015「GAIA 测什么？」

Qwen14b 答：“GAIA（Global AI Assessment Infrastructure and Analytics）……”

问题：全称编错，内容泛泛而谈

特征：对 2023 年后提出的新概念完全没有认知，模型会强行编造一个看似合理的全称和解释。

类型三：知识不完整（40%）——最大类

GS-021「针对 LLM 应用的‘数据泄露测试’测什么？」

期望答案：测系统提示、训练数据、用户隐私、API 密钥泄露，核心是“信息隔离边界”

Qwen14b 答：系统提示泄露、用户隐私、API 密钥、训练数据四类都答对了

漏掉：“信息隔离边界”这一核心概念，得分 60/100

GS-027「混合 Judge 是什么？」

期望答案：规则判断可枚举维度（覆盖度、分类），模型判断需语义理解的维度（幻觉、预期准确性）

Qwen14b 答：“结合人工制定规则和机器学习模型……”

漏掉：没区分“规则适合什么、模型适合什么”，得分 50/100

特征：模型有基础认知，但缺少领域深度——像“听说过但没深入研究过”。

五、根因分析

5.1 知识时效性（17%失败）

概念	提出时间	Qwen2.5 训练数据可能截止
SWE-bench	2023.10	2024 年中
GAIA	2023.11	2024 年中
MCP	2024.11	无法覆盖

Qwen2.5 训练数据截止于 2024 年中期，对之后的新概念（MCP）完全无法覆盖，对之前的概念（SWE-bench、GAIA）仅有模糊印象。这是硬伤，prompt 无法解决。

5.2 领域深度不足（40%失败）

模型对 LLM 评测领域的主干概念有认知（幻觉、越狱、提示注入等），但缺少深度细节：

- 知道幻觉定义，不知道三种类型
- 知道越狱概念，不知道具体手法
- 知道 Judge 概念，不知道校准方法

这是训练数据分布问题——LLM 评测是细分领域，公开语料相对稀少。

5.3 通用套话倾向（27%失败）

模型倾向用通用最佳实践回答专业问题：

- 问“LLM 测试的难点”→ 答“主观性、公平性、伦理性”
- 问“评测集构建”→ 答“多样性、代表性、客观性”
- 问“AI 落地”→ 答“需求分析、技术选型、数据准备”

这些答案本身正确，但对领域专业问题来说太泛。这是 7B-14B 级别模型的共同特征——知识广度有，但专业深度不足，倾向于输出“安全但无用”的泛泛答案。

六、结论

6.1 核心结论

Qwen2.5:14b 不适用于 LLM 评测领域的知识问答任务。

- 均分 28.2，远低于可用阈值（70+）
- 43%的题目完全失败（0-19 分）
- 仅 7%的题目完全正确（70-100 分）

6.2 失败特征

在 28 条未完全正确的题中，失败类型分布如下：

失败类型	条数	占失败题比例
通用套话	8	28.6%
知识缺失	5	17.9%
知识不完整	12	42.9%
术语误解	2	7.1%
其他	1	3.6%
合计	28	100%

三层叠加：

- 知识时效性（17.9%）：训练数据截止，新概念缺失
- 领域深度不足（42.9%）：有主干认知，缺细节
- 通用套话倾向（28.6%）：答案正确，但不对题

6.3 适用建议

场景	推荐

LLM 评测领域知识问答	必须用 API 强模型（DeepSeek、GPT-4 等）
本地部署场景	至少 32B+，或配合 RAG 补充最新知识
通用问答/业务场景	Qwen2.5:14b 可胜任（本次评测仅限专业领域）
有明确格式约束的任务	可用，但需人工抽检

七、方法论反思

7.1 本次评测的有效性

验证项	结果
Golden Set 难度分层	有效（DeepSeek 分数随难度递减）
Judge 判分准确性	逐项核对，扣分有据（人工抽查 6 条确认）
区分度	强（85.7 vs 28.2）
可复现性	部分（temperature=0.1，seed=42，非严格可复现）

7.2 发现的问题及修正

问题：3 条题目存在中文术语歧义，导致模型理解成另一个概念：

id	原题	模型误解成
GS-004	上下文污染是什么？怎么测？	训练数据污染（data contamination）
GS-021	数据泄露测试测什么？	评测集泄漏进训练数据
GS-027	混合 Judge 是什么？	人机混合/多 Judge 集成

修正：通过加限定词消除歧义：

id	原题	改后
GS-004	上下文污染是什么？怎么测？	多轮对话中的‘上下文污染’是什么？怎么测？
GS-021	数据泄露测试测什么？	针对 LLM 应用的‘数据泄露’测试测什么？（即模型输出是否会暴露系统提示、用户隐私、API 密钥等）

GS-027	混合 Judge 是什么?	LLM 评测中的 ‘混合 Judge’ （规则+模型）是什么?

改题效果：DeepSeek 在 GS-004/021/027 上均得 100 分；Qwen14b 在 GS-004 得 90 分，GS-021 得 60 分，GS-027 得 50 分。

教训：中文术语多义性会显著影响评测，题目需明确限定词。

7.3 可改进方向

- 增加 Judge 模型的多样性：用不同 Judge 交叉验证评分一致性
- 加入人工抽检环节：对 Judge 分数异常条目进行人工复核
- 评分标准更语义化：减少“要求出现特定词”的机械判分
- 扩大题集规模：30 条偏少，每个分类建议 10+条

八、附录

8.1 数据文件清单

文件	内容	生成时间
golden_set.json	30 条评测题目	2026-10
eval_results_deepseek.jsonl	DeepSeek 的 30 条回答	2026-10
eval_results_qwen14b.jsonl	Qwen2.5:14b 的 30 条回答	2026-10
scored_results.jsonl	DeepSeek 的评分结果	2026-10
scored_results_qwen14b.jsonl	Qwen2.5:14b 的评分结果	2026-10
score_report.json	DeepSeek 汇总报告	2026-10
score_report_qwen14b.json	Qwen2.5:14b 汇总报告	2026-10
failure_analysis.json	失败模式分档	2026-10

报告结束。

配套文档：《评测体系方法论》——本报告为探索期案例。