Judge 偏差检测报告 V1.1

报告日期：2026 年 10 月 15 日

评测对象：Judge（DeepSeek-Chat）

评测方式：位置偏差检测（原顺序 vs 交换顺序）

报告人：王晓芳

王晓芳 | AI测试评测 | 2026-10

目录

1. 摘要 3

2. 实验设计 3

2.1 目标 3

2.2 方法 3

2.3 数据 3

2.4 判定标准 4

3. 结果数据 4

3.1 整体偏差 4

3.2 逐题偏差 4

3.3 偏差分布 5

4. 分析 5

4.1 偏差幅度评估 5

4.2 偏差大的 case 5

4.3 偏差原因推测 6

4.4 对模型选型的影响 6

5. 结论 6

5.1 核心结论 6

5.2 建议 6

5.3 是否需要矫正 7

6. 下一步 7

附录：逐样本数据 7

王晓芳丨AI测试评测丨2026-10

1. 摘要

本报告检测 LLM-as-Judge（DeepSeek-Chat）是否存在位置偏差：对同一答案，交换“标准答案”和“模型回答”的位置，看打分是否一致。

核心发现：

- Judge 有轻微位置偏差：平均绝对差值 6 分。
- 10 个样本中，7 条无偏差，3 条有偏差（幅度 10-30 分）。
- Q15a DeepSeek 偏差最大（-30 分）。
- 整体可控，不影响模型选型结论。
- 建议：正式评测固定顺序 + 关键题多次评测。

2. 实验设计

2.1 目标

验证 Judge 对同一答案在不同位置的打分是否一致。

2.2 方法

对同一道题、同一个模型回答，跑两次 Judge：

顺序	Prompt 结构
原顺序	问题 → 标准答案 → 评分标准 → 模型回答
交换顺序	问题 → 模型回答 → 标准答案 → 评分标准

对比两次打分，计算差值。

2.3 数据

项	说明
题目	Q6、Q15a、Q15b、Q16、Q18（5 题）
模型	DeepSeek、Qwen2.5:14b（2 个）
样本数	5 题 × 2 模型 = 10 个
Judge	DeepSeek-Chat，temperature=0
总调用	10 样本 × 2 次 = 20 次 Judge

2.4 判定标准

平均绝对差值	判定
≤ 5	偏差小，Judge 可靠
5-20	轻微偏差，需注意
> 20	偏差大，需修 Judge prompt

3. 结果数据

3.1 整体偏差

指标	值
样本数	10
平均偏差	0
平均绝对偏差	6
最大正偏差	20
最大负偏差	-30

结论：平均绝对差值 6 分，属于“轻微偏差”。

3.2 逐题偏差

注：本次偏差检测为独立专项抽样实验，旨在验证 Judge 对信息位置是否敏感。测试样本与常规全量评测的分数可能有差异，属正常现象，重点观察“正反向测试的差值”。

题号	模型	原顺序	交换	差值
Q6	DeepSeek	100	100	0
Q6	Qwen	100	100	0
Q15a	DeepSeek	70	100	-30
Q15a	Qwen	100	100	0
Q15b	DeepSeek	100	100	0
Q15b	Qwen	100	100	0
Q16	DeepSeek	80	80	0
Q16	Qwen	60	40	+20
Q18	DeepSeek	30	30	0
Q18	Qwen	70	60	+10

3 条有偏差，7 条无偏差。

3.3 偏差分布

差值范围	条数	占比
0	7	70%
±10	1	10%
±20	1	10%
±30	1	10%

4. 分析

4.1 偏差幅度评估

平均绝对差值 6 分，属于“轻微偏差”。

判定标准	你的结果	结论
≤ 5	6	略高于阈值
5-20	6	轻微偏差
> 20	6	未达到

结论：Judge 有轻微位置偏差，但整体可控。

4.2 偏差大的 case

Q15a DeepSeek：-30 分（原顺序 70，交换 100）

- 原顺序：标准答案在前，Judge 给 70
- 交换顺序：模型回答在前，Judge 给 100

可能原因：Q15a 的评分标准是数组格式，Judge 对“标准答案在前” vs “模型回答在前”的处理不一致。当模型回答在前时，Judge 可能更关注回答本身，忽略了标准答案的细节。

Q16 Qwen：+20 分（原顺序 60，交换 40）

- 原顺序：标准答案在前，Judge 给 60
- 交换顺序：模型回答在前，Judge 给 40

可能原因：方向与 Q15a 相反，说明 Judge 的偏差不是单向的。

4.3 偏差原因推测

原因	说明
顺序敏感性	Judge 对信息出现顺序敏感，先看到的权重更高
评分标准格式	数组格式的评分标准（如 Q15a）更容易触发偏差
答案长度	长答案在前时，Judge 可能更仔细看；短答案在前时，可能忽略细节
锚定效应	Judge 先看到标准答案，会锚定；先看到模型回答，会独立判断

4.4 对模型选型的影响

Qwen vs DeepSeek 的差距是 7.89 分，Judge 偏差是 6 分。

项	值
模型差距	7.89 分
Judge 偏差	6 分
结论	偏差幅度小于模型差距，不影响选型结论

5. 结论

5.1 核心结论

- Judge 有轻微位置偏差：平均绝对差值 6 分。
- 10 个样本中，7 条无偏差，3 条有偏差（幅度 10-30 分）。
- Q15a DeepSeek 偏差最大（-30 分）。
- 偏差幅度小于模型差距（7.89 分），不影响模型选型结论。
- 整体可控，但正式评测需注意。

5.2 建议

建议	说明

固定顺序	所有评测都用“标准答案在前”的顺序，不做交换
关键题多次评测	跑 3 次，取均值，减少偏差影响
人工复核	偏差大的题（>20 分）人工确认
V2.0 改进	用不同 Judge 交叉验证，引入位置偏差校准系数

5.3 是否需要矫正

不需要。

- 偏差幅度可控（6 分 < 模型差距 7.89 分）
- 矫正可能引入新问题（过拟合）
- 成本高（改 prompt、重跑、重新校准）
- 不是阻塞项

记录 + 缓解即可。

6. 下一步

事项	说明
换 Judge 交叉验证	用 Qwen 或 GPT-4 做 Judge，对比一致率
引入校准系数	对偏差大的题型（如 conflict）加校准系数
人工复核机制	偏差>20 分的题，人工复核
季度回归	Judge 更新后，重跑偏差检测

附录：逐样本数据

题号	模型	原顺序	交换	差值
Q6	DeepSeek	100	100	0
Q6	Qwen	100	100	0
Q15a	DeepSeek	70	100	-30
Q15a	Qwen	100	100	0
Q15b	DeepSeek	100	100	0
Q15b	Qwen	100	100	0

Q16	DeepSeek	80	80	0
Q16	Qwen	60	40	+20
Q18	DeepSeek	30	30	0
Q18	Qwen	70	60	+10

报告结束。

配套文档：《AI 评测体系方法论》——本报告结论将整合进第 4 章“评分体系”（Judge 工程可靠性）。

王晓芳丨AI测试评测丨2026-10